

ESCUELA DE
INGENIERÍA INFORMÁTICA



PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

PROGRAMACIÓN DE CIRUGÍAS ELECTIVAS MEDIANTE BÚSQUEDA TABÚ Y SELECCIÓN ADAPTATIVA DE MOVIMIENTOS

JOSÉ BASUALTO

CRISTOPHER DAUROS

CARLOS RUZ

PRIMER INFORME

OII464: DESARROLLO DE DISEÑOS HÍBRIDOS PARA OPTIMIZACIÓN

2 DE OCTUBRE DE 2026

RESUMEN

La programación de cirugías electivas requiere coordinar anestesia y cirugía con salas y profesionales compartidos. Una secuencia inadecuada prolonga la jornada y puede bloquear recursos durante la espera entre etapas. Las metaheurísticas permiten explorar calendarios, pero la utilidad de sus movimientos puede variar durante la búsqueda. Este proyecto propone integrar búsqueda tabú con un bandido multibrazo dinámico (D-MAB) que aprende en línea qué movimiento conviene proponer a partir de las mejoras observadas. La intervención del aprendizaje se ubica en la evolución de la búsqueda, mediante selección de operadores y generación de vecinos. Como respaldo, una cartera fija ejecutará Tabu con selección uniforme y Tabu con D-MAB, conservando el mejor calendario factible bajo un presupuesto total compartido. El modelo mantendrá estrictas las restricciones de recursos y de espera máxima. La evaluación distinguirá el aporte del aprendizaje del beneficio de repetir la búsqueda, mediante controles y ablaciones con igual presupuesto. Se medirán calidad, bloqueo, tiempo y robustez en instancias sintéticas. Los pilotos no demuestran superioridad general; la contribución esperada es identificar condiciones en que la adaptación aporta mejoras reproducibles y justificar su costo computacional.

Palabras clave: programación de cirugías; búsqueda tabú; selección adaptativa de operadores; aprendizaje en línea; bloqueo.

1. Introducción

El caso docente de OII464 programa pacientes previamente planificados en anestesia y cirugía, con preparación, transición, limpieza y recursos elegibles. Esperar la segunda sala puede retener la primera y su profesional. Se busca reducir el makespan y el bloqueo, respetando precedencia, espera máxima y disponibilidad (Lara Arce, 2026). El makespan depende del calendario, no corresponde a sumar las duraciones fijas.

La literatura distingue roles del aprendizaje: Akbarzadeh y Maenhout (2024) predicen factibilidad en secuencias quirúrgicas multifase; Niroumandrad et al. (2024) orientan Tabu con clasificadores para programar médicos. En selección de operadores, Yu et al. (2024) emplean Q-learning en programación y reprogramación quirúrgica, y el preprint de Dolatkah et al. (2026) usa D-MAB dentro de un algoritmo genético para generar columnas iniciales. Yin et al. (2026) aportan Tabu iterado multioperador entre hospitales, mientras DaCosta et al. (2008) constituyen el fundamento histórico de D-MAB. Difieren en representación, restricciones y evaluación; queda por establecer el aporte de D-MAB al Tabu del caso docente de dos etapas con espera estricta, reparación y controles de cómputo.

El objetivo es evaluar cuándo la selección adaptativa mejora calidad, tiempo o robustez frente a la uniforme. La arquitectura integra una metaheurística (MH) y aprendizaje automático (ML) en la *evolución*: selección de operadores y vecinos (Vega, s.f.). Tabu mantiene una trayectoria y utiliza instancias sintéticas docentes (Saicooh, 2026). Los pilotos no demuestran superioridad general.

2. Propuesta metodológica

2.1. Problema, representación y factibilidad

La agenda será estática, con duraciones conocidas. La solución fija orden y salas independientes por etapa; el planificador asigna profesionales elegibles disponibles. La espera y el fin de jornada son

$$W_j = \max\{0, T_j^C - F_j^A\}, \quad 0 \leq W_j \leq L_j, \quad C_{\max} = \max_{j \in J} F_j^C. \quad (1)$$

J es el conjunto de pacientes y j un paciente; T_j^C es el inicio de cirugía; F_j^A y F_j^C son los fines de cada etapa, incluida limpieza; W_j es la espera; L_j su límite estricto, y $C_{\max}$ el makespan. Las reservas siguen el modelo docente; la primera sala permanece ocupada hasta el traslado si las salas difieren.

Se usará el criterio existente, sin penalización por desequilibrio de salas:

$$f(S) = C_{\max} + 10^{-6} \sum_o t_o^{\text{ini}} + 0,5 \sum_{j \in J} W_j + 1,4 \max_{j \in J} W_j. \quad (2)$$

S es un calendario y $f(S)$ su objetivo; o recorre las operaciones y t_o^{ini} es su inicio de reserva. $C_{\max}$, J y W_j se definieron en (1). El coeficiente 10^{-6} desempata; 0,5 y 1,4 ponderan espera total y máxima. Se reportarán estas métricas por separado: una reducción de f no equivale necesariamente a la misma reducción del makespan.

Las claves aleatorias representan orden y salas. El decodificador pospone pacientes no programables y repara asignaciones. La reparación puede alterar el movimiento y restringir calendarios alcanzables; se registrará su efecto sobre la atribución de recompensas.

2.2. Componente MH: búsqueda tabú

Tabu parte de la mejor de treinta soluciones: FIFO (orden original), SPT y LPT (duración total creciente y decreciente) y veintisiete aleatorias. Propone intercambio, inserción y cambio de sala de anestesia, cirugía o ambas. Explora lotes de quince candidatos, priorizando pacientes con espera. Recuerda siete soluciones, con aspiración por mejora global; si ninguna es admisible, usa la mejor del lote. Puede aceptar empeoramientos locales y conserva el mejor resultado global.

2.3. Componente ML: selección adaptativa en la evolución

D-MAB elige el movimiento de cada candidato; cada operador es un brazo. UCB1 combina recompensa media y exploración de brazos menos probados. Page–Hinkley detecta caídas y reinicia estimaciones, conservando Tabu; es una prueba estadística del controlador (DaCosta et al., 2008). La recompensa es la mejora positiva del candidato reparado frente al estado local del lote, normalizada en $[0, 1]$; los duplicados reciben cero sin consumir evaluación. Se aprende durante la corrida, sin entrenamiento previo. ML decide qué vecinos proponer en la evolución de la trayectoria; el planificador asegura factibilidad y Tabu selecciona el vecino aceptado.

2.4. Orquestación y cartera con respaldo

Fuera de línea se prepararán instancias y calibrarán parámetros con datos exploratorios separados. En línea se generarán, repararán y evaluarán candidatos, actualizando Tabu y D-MAB. Se partirá de exploración $C = 0,1$, umbral Page–Hinkley $\lambda = 1$ y margen del detector $\delta = 0,01$; estos parámetros se revisarán en desarrollo.

La cartera inicial ejecuta secuencialmente Tabu uniforme y Tabu con D-MAB, cada uno con 3.030 evaluaciones, incluidas sus treinta inicializaciones. Ambos comparten instancia, semilla y configuración inicial, pero mantienen memorias y trayectorias independientes. Se devuelve el mejor calendario factible de los dos. El criterio de parada suma 6.060 evaluaciones; la comprobación final del calendario se registra aparte del presupuesto de búsqueda.

El reparto 50/50 es fijo y no aprende qué camino ganará. Conserva el objetivo de Tabu de 3.030 evaluaciones, sin garantizar superar a Tabu de 6.060. La entrada ejecutable guarda ambos caminos y el calendario elegido.

2.5. Datos, controles y plan de evaluación

Se partirá de doce YAML oficiales: tres réplicas de 15, 20, 25 y 30 cirugías. Se comprobarán esquema, hashes, elegibilidad y unidades temporales. El tamaño, los recursos, las duraciones y la espera permitida son metacaracterísticas descriptivas; no son entradas contextuales de D-MAB. Las nuevas semillas no sustituyen una evaluación en instancias reservadas. Durante el semestre se incorporarán escenarios de mayor congestión y tamaños de 50, 100 y 150 cirugías, ajustando recursos y declarando su procedencia sintética.

Tabla 1: Controles y ablaciones para identificar el aporte del aprendizaje.

Comparación	Propósito
FIFO, SPT y LPT	Referencias constructivas; también inicializan la búsqueda.
Tabu uniforme	Medir el efecto de aprender con los mismos movimientos.
Dos Tabu uniformes	Separar aprendizaje de diversidad por repetir la búsqueda.
Tabu con D-MAB	Aislar el camino aprendido frente a la cartera completa.
UCB1 sin detector	Ablación del reinicio Page–Hinkley.

Se medirán objetivo, makespan, espera total y máxima, factibilidad, tiempo y convergencia; la robustez se estimará entre semillas. Se emparejarán instancias y semillas, con presupuestos de evaluaciones iguales entre estrategias y, en pruebas separadas, igual tiempo máximo. La incertidumbre se agrupará por instancia, con contrastes corregidos por comparaciones múltiples.

Los pilotos en 240 pares con semillas 60–79 no muestran ventaja general significativa; LinUCB tampoco justificó otro controlador. En 30 cirugías, la cartera tardó aproximadamente nueve segundos de media con tareas concurrentes; no se proyecta ese tiempo a 150 cirugías. Se usarán datos sintéticos sin identificadores clínicos. Los controles y registros abordarán el riesgo de atribuir a ML mejoras por mayor cómputo o por reparación.

3. Conclusión

La programación de cirugías electivas exige coordinar salas y profesionales en dos etapas, reduciendo el makespan y el bloqueo sin incumplir la espera máxima. El proyecto estudiará si aprender qué movimientos proponer aporta calidad, eficiencia o robustez frente a una selección uniforme bajo las mismas restricciones y recursos de cómputo. La propuesta integra Tabu Search con D-MAB en la evolución de la búsqueda, mediante selección adaptativa de operadores y generación de vecinos, y añade una cartera fija que conserva el mejor calendario de Tabu uniforme y del camino aprendido. Los antecedentes y los pilotos fundamentan su factibilidad, pero la ausencia de una ventaja general demostrada exige separar el efecto del aprendizaje de repetir la búsqueda, controlar la reparación y evaluar escenarios reservados de mayor congestión. La contribución esperada es una adaptación reproducible al caso docente y evidencia sobre cuándo conviene utilizarla, cuánto cómputo requiere y qué limitaciones deben resolverse para ampliar la escala durante el semestre.

REFERENCIAS

- Akbarzadeh, B., & Maenhout, B. (2024). A two-layer heuristic for patient sequencing in the operating room theatre considering multiple resource phases. *Computers & Operations Research*, 170, 106768. <https://doi.org/10.1016/j.cor.2024.106768>
- DaCosta, L., Fialho, A., Schoenauer, M., & Sebag, M. (2008). Adaptive operator selection with dynamic multi-armed bandits. *Proceedings of the Genetic and Evolutionary Computation Conference*, 913-920. <https://doi.org/10.1145/1389095.1389272>
- Dolatkhah, M., Hashemi Doulabi, H., Rei, W., & Gendreau, M. (2026, 24 de abril). *A reinforcement-learning-based column generation algorithm for integrated operating room planning and scheduling* [Preprint, versión 1]. arXiv: 2604.22977. <https://doi.org/10.48550/arXiv.2604.22977>
- Lara Arce, J. (2026, agosto). *Programación de cirugías electivas* [Material de clase, OII464].
- Niroumandrad, N., Lahrichi, N., & Lodi, A. (2024). Learning tabu search algorithms: A scheduling application. *Computers & Operations Research*, 170, 106751. <https://doi.org/10.1016/j.cor.2024.106751>
- Saicooh. (2026). *OII464_Hospitales* [Repositorio docente de código e instancias]. https://github.com/Saicooh/OII464_Hospitales
- Vega, E. (s.f.). *Taxonomía ML → MH (visión general)* [Material de clase de OII464, diapositiva 6].
- Yin, D., Wang, J., Wang, Y., & Punnen, A. (2026). Multi-operator driven iterated tabu search for inter-hospital operating room scheduling. *Journal of the Operational Research Society*, 77(9), 2606-2626. <https://doi.org/10.1080/01605682.2025.2554741>
- Yu, H., Gao, K.-Z., Wu, N., & Suganthan, P. N. (2024). Ensemble meta-heuristics and Q-learning for staff dissatisfaction constrained surgery scheduling and rescheduling. *Engineering Applications of Artificial Intelligence*, 134, 108668. <https://doi.org/10.1016/j.engappai.2024.108668>