

Selección adaptativa de movimientos en Tabu Search para la programación de cirugías electivas

José Basualto, Cristopher Dauros y Carlos Ruz

Primer informe — 30 de septiembre de 2026

Resumen

La programación de cirugías electivas exige ordenar pacientes y coordinar quirófanos, anes-
tesiólogos y cirujanos en dos etapas sujetas a tiempos de preparación, transición y limpieza.
Una cirugía que no puede comenzar a tiempo tras la anestesia retiene recursos y puede exce-
der la espera máxima permitida. El problema combina decisiones discretas de secuenciación
y asignación con restricciones temporales estrictas. Proponemos estudiar una búsqueda tabú
integrada con un bandido multibrazo dinámico (D-MAB) que aprende durante cada corrida
cuál de cinco movimientos conviene explorar: intercambio, inserción y tres cambios de sala. El
aprendizaje utiliza la mejora observada de candidatos factibles; una prueba de cambio reinicia
sus estimaciones cuando el rendimiento de los movimientos varía. El objetivo experimental
prioriza el tiempo de terminación de la última cirugía y las esperas por bloqueo, sin imponer
equilibrio artificial entre salas. La propuesta se contrastó preliminarmente en instancias sintéticas
del curso con el mismo planificador, presupuesto y semillas para Tabu sin aprendizaje y Tabu
con D-MAB. Se informan calidad, tiempo, factibilidad y robustez, junto con una ablación del
mecanismo dinámico. El aporte esperado es evidencia reproducible sobre cuándo la selección
adaptativa de movimientos resulta útil en este caso hospitalario.

Palabras clave: programación de cirugías; búsqueda tabú; selección adaptativa de operadores;
bandido multibrazo; bloqueo.

1. Introducción

Una jornada de cirugías electivas debe usar salas y personal especializado sin superponer
operaciones incompatibles. En el caso propuesto para OII464, cada paciente pasa por anestesia y
cirugía; las salas elegibles, el personal, las duraciones y los tiempos de transición provienen de una
instancia. Una mala secuencia puede retrasar el término de la jornada y dejar un quirófano ocupado
mientras el paciente espera cirugía. Por ello interesa reducir el *makespan*, o instante de finalización
de la última operación, y las esperas por bloqueo, cumpliendo siempre el máximo de espera de cada
paciente. El catálogo disponible contiene instancias *sintéticas* en YAML, no registros clínicos ni los
archivos JSON mencionados en la presentación del taller (Saicooh, 2026).

El repositorio docente facilita instancias y un planificador, pero sus algoritmos históricos y sus
rutas de evaluación no comparten necesariamente el mismo tratamiento del límite de espera ni la
misma función objetivo. Para estudiar el aporte de una arquitectura híbrida, las alternativas deben

usar un único evaluador estricto, idénticas soluciones de partida y el mismo número de evaluaciones. Además, una mezcla fija de movimientos no puede responder a cambios en su utilidad durante la búsqueda. Nuestra pregunta es: *¿mejora la selección online de movimientos mediante D-MAB la calidad y robustez de Tabu Search frente a una mezcla fija, bajo el mismo presupuesto y las mismas restricciones?* El objetivo es diseñar la comparación y establecer una implementación reproducible; una mejora general aún no está demostrada.

La investigación relacionada ofrece fundamentos, pero no resuelve directamente esta comparación. Akbarzadeh y Maenhout (2024) modelan fases y recursos quirúrgicos con una heurística de dos niveles y predicción de factibilidad; Yin et al. (2026) estudian Tabu con múltiples operadores en programación entre hospitales. La adaptación de movimientos ya cuenta con precedentes: Yu et al. (2024) emplean Q-learning para seleccionar operadores en cirugía y Niroumandrad et al. (2024) guían Tabu con clasificadores en planificación clínica. DaCosta et al. (2008) introducen D-MAB, que combina selección tipo UCB con detección de cambios, aunque lo prueban en escenarios artificiales; Dolatkah et al. (2026) lo aplican a operadores de un algoritmo genético para quirófanos. En consecuencia, el aporte propuesto es *evaluar* D-MAB dentro de Tabu en las instancias del curso, con espera máxima estricta y una comparación de recursos homogénea; no se reivindica la primera aplicación de aprendizaje a cirugías.

2. Propuesta metodológica

2.1. Problema, factibilidad y objetivo

Sea J el conjunto de pacientes. Una solución $S = (\pi, \rho_1, \rho_2)$ contiene una permutación π y una sala elegible para la anestesia y otra para la cirugía de cada paciente. Ambas salas pueden diferir. El planificador construye el calendario según la disponibilidad de salas y personal, respetando precedencias, preparación, transición y limpieza. Se acepta una solución solo si cada paciente satisface su límite de espera entre ambas operaciones. Esta condición se trata como *restricción dura*, no como una penalización negociable.

Minimizamos, en minutos,

$$f(S) = C_{\max}(S) + 10^{-6} \sum_o t_o^{\text{inicio}} + 0,5 \sum_{j \in J} W_j + 1,4 \max_{j \in J} W_j, \quad (1)$$

donde W_j es el intervalo entre el fin de anestesia, incluida su limpieza, y el inicio efectivo de cirugía; t_o^{inicio} marca el inicio de ocupación del recurso, incluida la preparación. El término de inicios rompe empates de manera marginal. El *makespan* se reporta por separado. La presentación docente contempla también una penalización de equilibrio de salas (Lara Arce, 2026); la excluimos porque una asignación desigual puede ser la mejor bajo las demás restricciones. Por tanto, nuestros valores de f no se equiparan con el puntaje histórico del repositorio.

2.2. Componentes y orquestación

La metaheurística es Tabu Search sobre las decisiones discretas de S . Se construyen 30 soluciones iniciales: FIFO, SPT y LPT, junto con 27 soluciones de claves aleatorias; se evalúan con el mismo planificador y la búsqueda comienza desde la mejor. Cada ronda considera 15 candidatos.

Los cinco movimientos posibles son intercambio de pacientes, inserción, reasignación de sala de anestesia, de sala de cirugía o de ambas. Una memoria tabú de longitud siete desincentiva regresar a soluciones recientes; la aspiración admite un movimiento tabú cuando supera el mejor valor global. Ese mejor valor se conserva aunque una ronda acepte un empeoramiento local.

El componente de aprendizaje es D-MAB (DaCosta et al., 2008), adaptado a los cinco movimientos. *Antes* de generar cada candidato, el controlador escoge uno con UCB1. Después de evaluarlo recibe una recompensa acotada a $[0, 1]$, proporcional a la mejora positiva respecto de la solución local, y actualiza su estimación del movimiento escogido. Page–Hinkley detecta caídas en esa recompensa y reinicia las estimaciones para volver a explorar. Este mecanismo aprende *online* dentro de cada corrida: no usa entrenamiento previo, no recibe las características de la instancia como vector contextual y no afirma reconocer directamente un óptimo local.

Flujo reproducible. *Offline:* seleccionar las instancias YAML, verificar su esquema, construir baselines y fijar parámetros, semillas y presupuesto. *Online:* elegir movimiento $\rightarrow$ generar candidato $\rightarrow$ decodificar y comprobar factibilidad $\rightarrow$ evaluar f $\rightarrow$ actualizar D-MAB y el estado Tabu. El criterio de parada es 3.030 evaluaciones estrictas por corrida, incluidas las 30 iniciales. Se registran también tamaño, número de salas, duraciones y límites de espera para analizar diferencias entre instancias. Ninguna instancia sintética contiene datos de pacientes reales.

2.3. Plan de evaluación

La comparación principal enfrentará Tabu con mezcla uniforme de los mismos cinco movimientos y Tabu con D-MAB por candidato. FIFO, SPT y LPT serán referencias constructivas. Una ablación retirará Page–Hinkley, dejando UCB1, para estimar el aporte de la detección de cambios. Se usaron las doce instancias estándar, tres réplicas de 15, 20, 25 y 30 cirugías, y semillas emparejadas; las instancias con doce salas ampliarán el estudio de escalabilidad. Los parámetros se fijaron con las corridas exploratorias antes de ejecutar semillas nuevas de validación.

Por instancia y método se reportan objetivo, $C_{\text{máx}}$, bloqueo, factibilidad, tiempo y curvas de convergencia. Las diferencias se calculan por parejas instancia–semilla; no se tratan las corridas como instancias independientes. El mismo presupuesto y planificador aíslan el aporte del controlador. Tras el piloto con semillas 0–19, la validación con semillas 20–39 sobre las mismas doce instancias encontró diferencias de ambos signos y un efecto mediano entre instancias cercano a cero. El bloqueo mediano fue cero en todos los tamaños, así que el catálogo discrimina poco esa métrica. No se demuestra ventaja general ni generalización a casos no vistos. El riesgo de ajustar el controlador a las instancias observadas se reduce al fijar sus parámetros antes de validar con semillas nuevas.

3. Conclusión

Se propone Tabu Search para programar cirugías bajo restricciones estrictas de recursos y espera. D-MAB aprende online qué movimiento discreto conviene explorar. La comparación con el mismo evaluador y presupuesto, más una ablación, permitirá medir cuándo aporta valor. La evidencia actual se limita a este catálogo sintético.

Referencias

- Akbarzadeh, B. y Maenhout, B. (2024). A two-layer heuristic for patient sequencing in the operating room theatre considering multiple resource phases. *Computers & Operations Research*, 170, 106768. doi:10.1016/j.cor.2024.106768.
- DaCosta, L., Fialho, A., Schoenauer, M. y Sebag, M. (2008). Adaptive operator selection with dynamic multi-armed bandits. En *Proceedings of GECCO* (pp. 913–920). doi:10.1145/1389095.1389272.
- Dolatkah, M., Hashemi Doulabi, H., Rei, W. y Gendreau, M. (2026). A reinforcement-learning-based column generation algorithm for integrated operating room planning and scheduling. *arXiv:2604.22977*, preprint. arXiv:2604.22977.
- Lara Arce, J. (2026). *Presentación Hospitales: Optativo* [material de clase, OII464, 7 de septiembre].
- Niroumandrad, N., Lahrichi, N. y Lodi, A. (2024). Learning tabu search algorithms: A scheduling application. *Computers & Operations Research*, 170, 106751. doi:10.1016/j.cor.2024.106751.
- Saicooh. (2026). *OII464_Hospitales* [repositorio docente]. github.com/Saicooh/OII464_Hospitales.
- Yin, D., Wang, J., Wang, Y. y Punnen, A. (2026). Multi-operator driven iterated tabu search for inter-hospital operating room scheduling. *Journal of the Operational Research Society*, 77(9), 2606–2626. doi:10.1080/01605682.2025.2554741.
- Yu, H., Gao, K.-Z., Wu, N. y Suganthan, P. N. (2024). Ensemble meta-heuristics and Q-learning for staff dissatisfaction constrained surgery scheduling and rescheduling. *Engineering Applications of Artificial Intelligence*, 134, 108668. doi:10.1016/j.engappai.2024.108668.