

ESCUELA DE
INGENIERÍA INFORMÁTICA



PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

PROGRAMACIÓN DE CIRUGÍAS ELECTIVAS MEDIANTE BÚSQUEDA TABÚ Y SELECCIÓN ADAPTATIVA DE MOVIMIENTOS

JOSÉ BASUALTO

CRISTOPHER DAUROS

CARLOS RUZ

PRIMER INFORME

OII464: DESARROLLO DE DISEÑOS HÍBRIDOS PARA OPTIMIZACIÓN

2 DE OCTUBRE DE 2026

RESUMEN

La programación de cirugías electivas exige coordinar las etapas de anestesia y cirugía, considerando la disponibilidad compartida de salas y profesionales para evitar que la espera entre procedimientos prolongue la jornada o bloquee recursos. Para abordar este problema, se propone integrar búsqueda tabú con un bandido multibrazo dinámico (D-MAB), que aprende durante la ejecución qué movimientos conviene utilizar y orienta así la generación de vecinos en la evolución de la búsqueda. La metodología incorpora una cartera con dos trayectorias, una de selección uniforme y otra guiada por D-MAB, que comparten un presupuesto total de evaluaciones y conservan el mejor calendario factible, respetando las restricciones de recursos y espera máxima. Su evaluación se realizará en instancias sintéticas mediante comparaciones y ablaciones con igual presupuesto, considerando calidad, bloqueo, tiempo y robustez para distinguir el aporte del aprendizaje del efecto de repetir la búsqueda. Con este diseño se busca identificar las condiciones en que la adaptación puede aportar mejoras reproducibles y determinar si estas justifican su costo computacional.

Palabras clave: programación de cirugías; búsqueda tabú; selección adaptativa de operadores; aprendizaje en línea; bloqueo.

1. Introducción

Organizar una jornada quirúrgica supone distribuir una capacidad limitada entre pacientes cuyas intervenciones tienen distintas duraciones y requerimientos. La disponibilidad de quirófanos y personal especializado, así como los tiempos de preparación y limpieza, condiciona tanto el orden de atención como el término de la jornada. Cuando la anestesia y la cirugía se realizan en etapas distintas, la espera por la segunda sala puede retener la primera y su profesional, prolongando la jornada y dificultando el uso de los recursos. En el problema considerado, se busca reducir el makespan, entendido como el tiempo de término de la última operación, y el bloqueo, respetando la precedencia, la espera máxima y la disponibilidad (Lara Arce, 2026). A diferencia de la suma de duraciones fijas, el makespan depende de cómo se ordenan los pacientes y se asignan los recursos.

La literatura distingue roles del aprendizaje: Akbarzadeh y Maenhout (2024) predicen factibilidad en secuencias quirúrgicas multifase; Niroumandrad et al. (2024) orientan Tabu con clasificadores para programar médicos. En selección de operadores, Yu et al. (2024) emplean Q-learning en programación y reprogramación quirúrgica, y el preprint de Dolatkah et al. (2026) usa D-MAB dentro de un algoritmo genético para generar columnas iniciales. Yin et al. (2026) aportan Tabu iterado multioperador entre hospitales, mientras DaCosta et al. (2008) constituyen el fundamento histórico de D-MAB. Difieren en representación, restricciones y evaluación; queda por establecer el aporte de D-MAB al Tabu del caso docente de dos etapas con espera estricta, reparación y controles de cómputo.

El objetivo de este proyecto es estudiar si la selección adaptativa de movimientos puede mejorar la calidad, el tiempo o la robustez de Tabu Search frente a la selección uniforme, integrando una metaheurística (MH) con aprendizaje automático (ML). Para ello, D-MAB orientará la generación de vecinos durante la *evolución* de la trayectoria (Vega, s.f.), y su aporte se evaluará con instancias sintéticas del repositorio oficial (Saicooh, 2026), mediante comparaciones con las mismas restricciones y presupuestos de búsqueda equivalentes.

2. Propuesta metodológica

2.1. Problema, representación y factibilidad

La agenda será estática, con duraciones conocidas. La solución fija orden y salas independientes por etapa; el planificador asigna profesionales elegibles disponibles. La espera y el fin de jornada son

$$W_j = \max\{0, T_j^C - F_j^A\}, \quad 0 \leq W_j \leq L_j, \quad C_{\max} = \max_{j \in J} F_j^C. \quad (1)$$

J es el conjunto de pacientes y j un paciente; T_j^C es el inicio de cirugía; F_j^A y F_j^C son los fines de cada etapa, incluida limpieza; W_j es la espera; L_j su límite estricto, y $C_{\max}$ el makespan. Las reservas siguen el modelo docente; la primera sala permanece ocupada hasta el traslado si las salas difieren.

Se minimizará el siguiente criterio, sin penalización por desequilibrio de salas:

$$f(S) = C_{\max} + 10^{-6} \sum_o t_o^{\text{ini}} + 0,5 \sum_{j \in J} W_j + 1,4 \max_{j \in J} W_j. \quad (2)$$

S es un calendario y $f(S)$ su objetivo; o recorre las operaciones y t_o^{ini} es su inicio de reserva. $C_{\max}$, J y W_j se definieron en (1). El coeficiente 10^{-6} desempata; 0,5 y 1,4 ponderan espera total y máxima. Se reportarán estas métricas por separado: una reducción de f no equivale necesariamente a la misma reducción del makespan.

Las claves aleatorias representan orden y salas. El decodificador pospone pacientes no programables y repara asignaciones. La reparación puede alterar el movimiento y restringir calendarios alcanzables; se registrará su efecto sobre la atribución de recompensas.

2.2. Componente MH: búsqueda tabú

Tabu parte de la mejor de treinta soluciones: FIFO (orden original), SPT y LPT (duración total creciente y decreciente) y veintisiete aleatorias. Propone intercambio, inserción y cambio de sala de anestesia, cirugía o ambas. Explora lotes de quince candidatos, priorizando pacientes con espera. Recuerda siete soluciones, con aspiración por mejora global; si ninguna es admisible, usa la mejor del lote. Puede aceptar empeoramientos locales y conserva el mejor resultado global.

2.3. Componente ML: selección adaptativa en la evolución

D-MAB elige el movimiento de cada candidato; cada operador es un brazo. UCB1 combina recompensa media y exploración de brazos menos probados. Page–Hinkley detecta caídas y reinicia estimaciones, conservando Tabu; es una prueba estadística del controlador (DaCosta et al., 2008). La recompensa es la mejora positiva del candidato reparado frente al estado local del lote, normalizada en $[0, 1]$; los duplicados reciben cero sin consumir evaluación. Se aprende durante la corrida, sin entrenamiento previo. ML decide qué vecinos proponer en la evolución de la trayectoria; el planificador asegura factibilidad y Tabu selecciona el vecino aceptado.

2.4. Orquestación y cartera con respaldo

Fuera de línea se prepararán instancias y calibrarán parámetros con datos exploratorios separados. En línea se generarán, repararán y evaluarán candidatos, actualizando Tabu y D-MAB. Se partirá de exploración $C = 0,1$, umbral Page–Hinkley $\lambda = 1$ y margen del detector $\delta = 0,01$; estos parámetros se revisarán en desarrollo.

La cartera inicial ejecuta secuencialmente Tabu uniforme y Tabu con D-MAB, cada uno con 3.030 evaluaciones, incluidas sus treinta inicializaciones. Ambos comparten instancia, semilla y configuración inicial, pero mantienen memorias y trayectorias independientes. Se devuelve el mejor calendario factible de los dos. El criterio de parada suma 6.060 evaluaciones; la comprobación final del calendario se registra aparte del presupuesto de búsqueda.

El reparto 50/50 es fijo y no aprende qué camino ganará. Conserva el objetivo de Tabu de 3.030 evaluaciones, sin garantizar superar a Tabu de 6.060. La entrada ejecutable guarda ambos caminos y el calendario elegido.

2.5. Datos, controles y plan de evaluación

Se trabajará con 12 instancias obtenidas del repositorio oficial del problema a estudiar, correspondientes a tres réplicas de 15, 20, 25 y 30 cirugías. Se comprobarán esquema, hashes, elegibilidad y unidades temporales. El tamaño, los recursos, las duraciones y la espera permitida son metacaracterísticas descriptivas; no son entradas contextuales de D-MAB. Las nuevas semillas no sustituyen una evaluación en instancias reservadas. Durante el semestre se incorporarán escenarios de mayor congestión y tamaños de 50, 100 y 150 cirugías, ajustando recursos y declarando su procedencia sintética.

Tabla 1: Controles y ablaciones para identificar el aporte del aprendizaje.

Comparación	Propósito
FIFO, SPT y LPT	Referencias constructivas; también inicializan la búsqueda.
Tabu uniforme	Medir el efecto de aprender con los mismos movimientos.
Dos Tabu uniformes	Separar aprendizaje de diversidad por repetir la búsqueda.
Tabu con D-MAB	Aislar el camino aprendido frente a la cartera completa.
UCB1 sin detector	Ablación del reinicio Page–Hinkley.

Se medirán objetivo, makespan, espera total y máxima, factibilidad, tiempo y convergencia; la robustez se estimará entre semillas. Se emparejarán instancias y semillas, con presupuestos de evaluaciones iguales entre estrategias y, en pruebas separadas, igual tiempo máximo. La incertidumbre se agrupará por instancia, con contrastes corregidos por comparaciones múltiples.

Se emplearán datos sintéticos sin identificadores clínicos y se registrarán el equipo, la configuración y el tiempo de ejecución de cada corrida, de modo que el costo computacional pueda analizarse al aumentar el tamaño de las instancias. Los controles y registros permitirán examinar el riesgo de atribuir al aprendizaje mejoras debidas a un mayor presupuesto o a la reparación de candidatos.

3. Conclusión

La arquitectura propuesta sitúa el aprendizaje en la evolución de Tabu Search, al utilizar D-MAB para seleccionar los movimientos que generan nuevos vecinos y una cartera fija para conservar el mejor calendario factible entre el camino uniforme y el adaptativo. Con ello, se establece una metodología reproducible para estudiar si la adaptación contribuye a reducir el makespan y el bloqueo, manteniendo estrictas las restricciones del problema.

La evaluación se organizará para distinguir el aporte del aprendizaje del efecto de repetir la búsqueda y del presupuesto computacional, evitando atribuir al controlador ventajas que correspondan a otros componentes. También se analizará cómo la reparación de candidatos influye en la utilidad observada de los movimientos. A lo largo del semestre se ampliarán las pruebas a escenarios reservados y de mayor congestión, con el propósito de determinar cuándo conviene utilizar la propuesta, qué costo implica y cuáles son sus límites al aumentar la escala.

REFERENCIAS

- Akbarzadeh, B., & Maenhout, B. (2024). A two-layer heuristic for patient sequencing in the operating room theatre considering multiple resource phases. *Computers & Operations Research*, 170, 106768. <https://doi.org/10.1016/j.cor.2024.106768>
- DaCosta, L., Fialho, A., Schoenauer, M., & Sebag, M. (2008). Adaptive operator selection with dynamic multi-armed bandits. *Proceedings of the Genetic and Evolutionary Computation Conference*, 913-920. <https://doi.org/10.1145/1389095.1389272>
- Dolatkhah, M., Hashemi Doulabi, H., Rei, W., & Gendreau, M. (2026, 24 de abril). *A reinforcement-learning-based column generation algorithm for integrated operating room planning and scheduling* [Preprint, versión 1]. arXiv: 2604.22977. <https://doi.org/10.48550/arXiv.2604.22977>
- Lara Arce, J. (2026, agosto). *Programación de cirugías electivas* [Material de clase, OII464].
- Niroumandrad, N., Lahrichi, N., & Lodi, A. (2024). Learning tabu search algorithms: A scheduling application. *Computers & Operations Research*, 170, 106751. <https://doi.org/10.1016/j.cor.2024.106751>
- Saicooh. (2026). *OII464_Hospitales* [Repositorio docente de código e instancias]. https://github.com/Saicooh/OII464_Hospitales
- Vega, E. (s.f.). *Taxonomía ML → MH (visión general)* [Material de clase de OII464, diapositiva 6].
- Yin, D., Wang, J., Wang, Y., & Punnen, A. (2026). Multi-operator driven iterated tabu search for inter-hospital operating room scheduling. *Journal of the Operational Research Society*, 77(9), 2606-2626. <https://doi.org/10.1080/01605682.2025.2554741>
- Yu, H., Gao, K.-Z., Wu, N., & Suganthan, P. N. (2024). Ensemble meta-heuristics and Q-learning for staff dissatisfaction constrained surgery scheduling and rescheduling. *Engineering Applications of Artificial Intelligence*, 134, 108668. <https://doi.org/10.1016/j.engappai.2024.108668>