

ESCUELA DE
INGENIERÍA INFORMÁTICA



PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

BÚSQUEDA TABÚ CON D-MAB PARA PROGRAMAR CIRUGÍAS ELECTIVAS

JOSÉ BASUALTO

CRISTOPHER DAUROS

CARLOS RUZ

PRIMER INFORME

OII464: DESARROLLO DE DISEÑOS HÍBRIDOS PARA OPTIMIZACIÓN

SEPTIEMBRE DE 2026

RESUMEN

La programación de cirugías electivas exige decidir el orden de los pacientes y coordinar quirófanos, anestesiólogos y cirujanos en dos etapas. Las salas pueden diferir entre anestesia y cirugía. La espera entre etapas debe respetar un máximo estricto. Una mala secuencia prolonga la jornada y retiene recursos. El desafío es reducir el tiempo de término de la última cirugía y esa espera sin relajar las restricciones clínicas y operativas.

Proponemos una búsqueda tabú para explorar intercambios, inserciones y cambios de sala. Un bandido multibrazo dinámico (D-MAB) aprende durante la corrida qué movimiento conviene proponer a partir de las mejoras observadas; un detector de cambios reinicia sus estimaciones si el rendimiento cae. Las Un planificador estricto repara y evalúa las soluciones. La comparación incluye Tabu con selección uniforme, una ablación sin detector y tres reglas constructivas, con igual presupuesto de evaluaciones.

Una validación preliminar con veinte semillas nuevas en doce instancias sintéticas produjo mejoras y empeoramientos de magnitud semejante: no demuestra una ventaja general del controlador. El bloqueo mediano fue cero, lo que limita la capacidad del catálogo para distinguir métodos en esa métrica. El aporte es un protocolo reproducible para estudiar cuándo conviene adaptar movimientos.

Palabras clave: programación de cirugías; búsqueda tabú; selección adaptativa de operadores; aprendizaje en línea; bloqueo.

1. Introducción

En la programación intrajornada de cirugías electivas se asignan recursos compartidos a operaciones con precedencia. El caso docente de OII464 contiene una etapa de anestesia y otra de cirugía por paciente. Cada una tiene duración, preparación, transición, limpieza y conjuntos de salas y personal elegible. Si el quirófano de cirugía no está disponible al terminar la anestesia, la primera sala y su profesional pueden permanecer retenidos hasta el traslado. Una solución debe evitar superposiciones de recursos y respetar la espera máxima de cada paciente. Minimizar la suma de duraciones no representaría el problema: las duraciones son datos, mientras que el orden y las asignaciones determinan cuándo termina la jornada. Por eso examinamos el *makespan* y, por separado, la espera entre etapas como indicador de bloqueo.

La presentación del taller propone integrar una metaheurística y mejorar reglas clásicas, además de reducir el *makespan* y evitar quirófanos bloqueados (Lara Arce, 2026). Para estudiar una arquitectura híbrida hace falta una comparación controlada: cambiar a la vez la regla de factibilidad, la representación o el presupuesto impediría atribuir diferencias al componente de aprendizaje. También importa que los movimientos discretos no tengan la misma utilidad durante toda la búsqueda. Una mezcla fija de intercambio, inserción y cambios de sala no responde a esa variación; un controlador en línea podría hacerlo, aunque su exploración y sus reinicios pueden asimismo perjudicar una corrida. La pregunta es si D-MAB mejora *de manera consistente* la calidad de Tabu Search frente a seleccionar los mismos movimientos uniformemente, manteniendo constantes el decodificador, el presupuesto y las soluciones iniciales.

Los trabajos relacionados motivan esta comparación, pero no la resuelven. Akbarzadeh y Maenhout (2024) incorporan varias fases de recursos y predicción de factibilidad en secuenciación quirúrgica; Yin et al. (2026) usan búsqueda tabú con varios operadores entre hospitales. La elección aprendida de operadores también tiene precedentes: Yu et al. (2024) emplean Q-learning en programación y reprogramación de cirugías, mientras Niroumandrad et al. (2024) guían Tabu con clasificadores en otra tarea clínica. DaCosta et al. (2008) proponen D-MAB para selección adaptativa, combinando UCB1 y detección Page–Hinkley, y Dolatkhah et al. (2026) ya aplican D-MAB a operadores genéticos en planificación de quirófanos. Esos aportes impiden reivindicar como novedad general el uso de aprendizaje o de D-MAB en este dominio. La brecha concreta de nuestro estudio es evaluar su integración *dentro de Tabu*, con espera máxima estricta, salas de ambas etapas independientes y una comparación emparejada sobre el caso del curso.

El objetivo de esta primera entrega es especificar la representación, los componentes metaheurístico y de aprendizaje, su interacción y un protocolo reproducible para medir calidad, tiempo y robustez. El repositorio docente (Saicooh, 2026) aporta contexto y datos sintéticos; se trabajó en un repositorio independiente. La presentación menciona cuatro archivos JSON, pero los experimentos disponibles aquí usan doce instancias YAML de la copia local del catálogo. Esta distinción y la función objetivo exacta se declaran para evitar comparaciones impropias con puntajes históricos.

2. Propuesta metodológica

2.1. Problema, decisiones y decodificación

Sea J el conjunto de pacientes. Una solución propuesta $S = (\pi, \rho^A, \rho^C)$ incluye una permutación π y una sala elegible para anestesia y otra, potencialmente distinta, para cirugía de cada paciente. El planificador asigna personal elegible y ubica cada etapa en el primer instante compatible con la disponibilidad de sala y profesional. Para el paciente j , sean F_j^A el fin de anestesia incluida su limpieza, T_j^C el inicio efectivo de cirugía y F_j^C el fin de cirugía incluida su limpieza. Definimos

$$W_j = \max\{0, T_j^C - F_j^A\}, \quad 0 \leq W_j \leq L_j, \quad C_{\max} = \max_{j \in J} F_j^C, \quad (1)$$

donde L_j es la espera máxima de la instancia. El límite se verifica como *restricción dura*: una propuesta que lo viola no puede ser la mejor solución. Además se exige elegibilidad y ausencia de superposición de salas y profesionales. Cuando las etapas usan salas distintas, la sala y el profesional de anestesia permanecen ocupados hasta T_j^C ; si comparten sala, ésta sigue ocupada durante la cirugía y limpieza. W_j mide la espera entre etapas usada como *proxy* de bloqueo, no toda la indisponibilidad de un quirófano.

La codificación de claves aleatorias genera preferencias de orden y de dos salas por paciente. Un decodificador repara esas preferencias: si el paciente preferido no es programable en ese momento, prueba los siguientes; para el elegido busca un par de salas factible que se aparte lo menos posible de las preferencias. El personal se asigna de manera voraz entre los elegibles. Por ello el movimiento solicitado puede convertirse en otra solución tras la reparación. El espacio realmente explorado depende de este decodificador y no comprende necesariamente todos los calendarios factibles. A diferencia del piloto inicial, no se fuerza equilibrio entre pabellones ni la misma sala para ambas etapas.

Minimizamos el criterio fijado antes de la validación,

$$f(S) = C_{\max} + 10^{-6} \sum_o t_o^{\text{ini}} + 0,5 \sum_{j \in J} W_j + 1,4 \max_{j \in J} W_j, \quad (2)$$

donde t_o^{ini} es el inicio de reserva del recurso para cada operación, incluida la preparación. El término 10^{-6} desempata soluciones próximas. Reportamos $C_{\max}$ y las esperas por separado: una mejora de f no implica que todas sus componentes disminuyan. La presentación docente considera también equilibrio de carga (Lara Arce, 2026); lo excluimos porque una asignación desigual puede minimizar mejor el tiempo y la espera. Por tanto, f no equivale al puntaje histórico del taller.

2.2. Componente metaheurístico: búsqueda tabú

La búsqueda comienza desde la mejor de treinta soluciones evaluadas con el mismo planificador: FIFO, SPT, LPT y veintisiete generadas por claves aleatorias. Las reglas clásicas forman parte de la inicialización, de modo que superarlas al final está garantizado por construcción y no demuestra por sí solo el aporte de Tabu o D-MAB. En cada ronda se generan quince candidatos distintos mediante cinco tipos de movimiento: intercambiar dos pacientes, extraer e insertar uno en otra posición, cambiar su sala de anestesia, cambiar la de cirugía o cambiar ambas. Con probabilidad

0,65 se elige un paciente entre los tres con mayor espera actual; en otro caso se elige del conjunto completo. El sesgo concentra parte de la búsqueda donde hay congestión, sin impedir exploración global.

La memoria tabú conserva las últimas siete soluciones para desincentivar retornos. Una aspiración permite aceptar una solución tabú si mejora el mejor valor global. El estado local puede empeorar para salir de una zona de búsqueda, pero el mejor calendario observado se guarda por separado. Las tres políticas comparadas comparten exactamente estos movimientos, la reparación, las soluciones iniciales y un máximo de 3.030 evaluaciones estrictas, incluidas las treinta iniciales.

2.3. Componente de aprendizaje y flujo

El aprendizaje se realiza *online* en cada corrida, sin entrenamiento previo ni un modelo contextual. Antes de generar cada candidato, D-MAB escoge un movimiento a mediante el índice UCB1

$$a^* = \arg \max_a \left(\bar{r}_a + \sqrt{\frac{2 \ln(\sum_b n_b)}{n_a}} \right), \quad (3)$$

tras probar inicialmente cada brazo. Aquí n_a es su número de observaciones y $\bar{r}_a$ su recompensa media. Después de evaluar el candidato se entrega una recompensa en $[0, 1]$:

$$r_a = \min \left\{ 1, \frac{\max\{0, f(S_{\text{local}}) - f(S_{\text{cand}})\}}{\max\{1, 0,02f(S_{\text{inicial}})\}} \right\}. \quad (4)$$

La referencia local se fija al comienzo del lote de quince candidatos. Una propuesta duplicada recompensa con cero al bandido, aunque no consume una evaluación estricta. Page–Hinkley detecta caídas de recompensa por brazo con $\delta = 0,01$ y umbral $\lambda = 0,35$; cuando dispara, reinicia las estimaciones de *todos* los movimientos, pero conserva la solución, la memoria tabú y el mejor valor. D-MAB aprende qué *propuesta más reparación* fue útil; no diagnostica directamente un óptimo local.

El flujo *offline* consiste en verificar instancias, definir función objetivo, parámetros, baselines y semillas. En línea se repite: seleccionar movimiento, generar vecino, reparar, comprobar factibilidad, evaluar, actualizar bandido y estado tabú. Como ablación, UCB1 usa la misma selección sin Page–Hinkley; Tabu mixto selecciona uno de los cinco movimientos con probabilidad uniforme. Así la comparación principal estima el efecto de la selección aprendida y la ablación aísla el reinicio dinámico.

2.4. Datos, evaluación y alcance de la evidencia

El catálogo contiene doce instancias sintéticas en YAML: tres réplicas de cada tamaño, con 15, 20, 25 y 30 cirugías. Se verifican esquema y hashes, y se registran tamaño, salas, personal, duraciones y límites de espera. Son características descriptivas para análisis posterior, no entradas del bandido. Al crecer el número de cirugías también crecen los recursos, por lo que una curva agrupada por tamaño no aísla el efecto del número de pacientes. Ninguna instancia contiene datos clínicos reales.

El piloto usó semillas 0–19 para fijar la arquitectura. La validación emparejada usó semillas 20–39 en *las mismas doce instancias*: tres políticas por instancia y semilla, 720 corridas y 2.181.600 evaluaciones estrictas presupuestadas. Comparamos diferencias por pareja instancia–semilla, además de medianas de objetivo, makespan, espera total y máxima, porcentaje factible, tiempo y curvas de convergencia ilustrativas. La mediana del tiempo por corrida fue cercana a 0,9 segundos. Una reejecución de 36 corridas reconstruyó calendarios factibles y reprodujo los valores guardados. La comparación frente a FIFO, SPT y LPT se muestra como referencia constructiva, con la salvedad de que estas reglas ya siembran la búsqueda.

Cuadro 1: Comparación preliminar frente a Tabu mixto en 240 pares instancia–semilla. Un cambio de hasta 0,25 min se considera similar.

Política	Mejora	Similar	Empeora
Tabu + UCB1	105	34	101
Tabu + D-MAB	106	39	95

El efecto de D-MAB cambia de signo entre instancias y la mediana de sus doce diferencias medianas respecto de Tabu mixto es aproximadamente cero. La ablación directa tampoco muestra una ventaja consistente del reinicio Page–Hinkley. El bloqueo total mediano fue cero en todas las instancias y políticas; este catálogo discrimina poco en esa métrica y las diferencias provienen principalmente del makespan. Las semillas nuevas permiten estudiar la variación aleatoria del algoritmo *dentro del catálogo conocido*, pero no prueban generalización a instancias no vistas ni optimalidad global. Como siguiente prueba se requieren instancias sintéticas de estrés con más congestión y un conjunto de instancias reservado antes de ajustar parámetros.

Amenazas de validez y trabajo siguiente. El presupuesto igualado cuenta llamadas al planificador estricto, no propuestas repetidas ni segundos de procesador. En efecto, una propuesta duplicada puede actualizar el bandido con recompensa cero sin gastar una evaluación, y la política uniforme no registra ese intento con la misma granularidad. La reparación puede modificar el movimiento escogido; por tanto, una preferencia aprendida por un brazo refleja la utilidad de proponerlo *junto con* su reparación, no el efecto puro de una operación de vecindario. Una evaluación posterior deberá registrar tasas de reparación, elecciones y recompensas por operador, y comparar además presupuestos de tiempo. También se requieren intervalos de incertidumbre agrupados por instancia: las veinte semillas de una misma réplica comparten los datos y no constituyen veinte problemas independientes. Finalmente, nuevas instancias con esperas más exigentes permitirán observar si el componente aprendido aporta valor precisamente donde hay riesgo de bloqueo.

3. Conclusión

El problema exige coordinar secuencia, salas y personal sin violar la espera máxima entre anestesia y cirugía. La propuesta combina Tabu Search con D-MAB para escoger movimientos según la recompensa observada durante cada corrida. La validación inicial no demuestra superioridad general del controlador y señala que el catálogo actual apenas discrimina bloqueo. El valor de la arquitectura reside en que deja aislado y reproducible el efecto del aprendizaje; las siguientes entregas deberán probarlo en instancias no observadas y con mayor congestión.

REFERENCIAS

- Akbarzadeh, B., & Maenhout, B. (2024). A two-layer heuristic for patient sequencing in the operating room theatre considering multiple resource phases. *Computers & Operations Research*, 170, 106768. <https://doi.org/10.1016/j.cor.2024.106768>
- DaCosta, L., Fialho, A., Schoenauer, M., & Sebag, M. (2008). Adaptive operator selection with dynamic multi-armed bandits. *Proceedings of the Genetic and Evolutionary Computation Conference*, 913-920. <https://doi.org/10.1145/1389095.1389272>
- Dolatkah, M., Hashemi Doulabi, H., Rei, W., & Gendreau, M. (2026). *A reinforcement-learning-based column generation algorithm for integrated operating room planning and scheduling* [Preprint]. arXiv: 2604.22977. <https://arxiv.org/abs/2604.22977>
- Lara Arce, J. (2026, 7 de septiembre). *Presentación Hospitales: Optativo* [Material de clase, OII464].
- Niroumandrad, N., Lahrichi, N., & Lodi, A. (2024). Learning tabu search algorithms: A scheduling application. *Computers & Operations Research*, 170, 106751. <https://doi.org/10.1016/j.cor.2024.106751>
- Saicooh. (2026). *OII464_Hospitales* [Repositorio docente de código e instancias]. https://github.com/Saicooh/OII464_Hospitales
- Yin, D., Wang, J., Wang, Y., & Punnen, A. (2026). Multi-operator driven iterated tabu search for inter-hospital operating room scheduling. *Journal of the Operational Research Society*, 77(9), 2606-2626. <https://doi.org/10.1080/01605682.2025.2554741>
- Yu, H., Gao, K.-Z., Wu, N., & Suganthan, P. N. (2024). Ensemble meta-heuristics and Q-learning for staff dissatisfaction constrained surgery scheduling and rescheduling. *Engineering Applications of Artificial Intelligence*, 134, 108668. <https://doi.org/10.1016/j.engappai.2024.108668>