

ESCUELA DE  
INGENIERÍA INFORMÁTICA



PONTIFICIA  
UNIVERSIDAD  
CATÓLICA DE  
VALPARAÍSO

# **PROGRAMACIÓN DE CIRUGÍAS ELECTIVAS MEDIANTE BÚSQUEDA TABÚ Y SELECCIÓN ADAPTATIVA DE MOVIMIENTOS**

**JOSÉ BASUALTO**

**CRISTOPHER DAUROS**

**CARLOS RUZ**

**PRIMER INFORME**

**OII464: DESARROLLO DE DISEÑOS HÍBRIDOS PARA OPTIMIZACIÓN**

**2 DE OCTUBRE DE 2026**

## RESUMEN

La programación de cirugías electivas exige decidir el orden de los pacientes y coordinar quirófanos, anestesiólogos y cirujanos en dos etapas. Las salas pueden diferir entre anestesia y cirugía. La espera entre etapas debe respetar un máximo estricto. Una mala secuencia prolonga la jornada y retiene recursos. El desafío es reducir el tiempo de término de la última cirugía y esa espera sin relajar las restricciones clínicas y operativas.

Proponemos una búsqueda tabú para explorar intercambios, inserciones y cambios de sala. Un bandido multibrazo dinámico (D-MAB) aprende durante la corrida qué movimiento conviene proponer a partir de las mejoras observadas; un detector de cambios reinicia sus estimaciones si el rendimiento cae. Un planificador estricto repara y evalúa las soluciones. La comparación incluye Tabu con selección uniforme, una ablación sin detector y tres reglas constructivas, con igual presupuesto de evaluaciones.

Una validación preliminar con veinte semillas nuevas en doce instancias sintéticas produjo mejoras y empeoramientos de magnitud semejante: no demuestra una ventaja general del controlador. El bloqueo mediano fue cero, lo que limita la capacidad del catálogo para distinguir métodos en esa métrica. El aporte es un protocolo reproducible para estudiar cuándo conviene adaptar movimientos.

**Palabras clave:** programación de cirugías; búsqueda tabú; selección adaptativa de operadores; aprendizaje en línea; bloqueo.

## 1. Introducción

En la programación intrajornada de cirugías electivas se asignan recursos compartidos a operaciones con precedencia. El caso docente de OII464 contiene una etapa de anestesia y otra de cirugía por paciente. Cada una tiene duración, preparación, transición, limpieza y conjuntos de salas y personal elegible. Si el quirófano de cirugía no está disponible al terminar la anestesia, la primera sala y su profesional pueden permanecer retenidos hasta el traslado. Una solución debe evitar superposiciones de recursos y respetar la espera máxima de cada paciente. Minimizar la suma de duraciones no representaría el problema: las duraciones son datos, mientras que el orden y las asignaciones determinan cuándo termina la jornada. Por eso examinamos el *makespan* y, por separado, la espera entre etapas como indicador de bloqueo.

La presentación del taller propone integrar una metaheurística y mejorar reglas clásicas, además de reducir el *makespan* y evitar quirófanos bloqueados (Lara Arce, 2026). Para estudiar una arquitectura híbrida hace falta una comparación controlada: cambiar a la vez la regla de factibilidad, la representación o el presupuesto impediría atribuir diferencias al componente de aprendizaje. También importa que los movimientos discretos no tengan la misma utilidad durante toda la búsqueda. Una mezcla fija de intercambio, inserción y cambios de sala no responde a esa variación; un controlador en línea podría hacerlo, aunque su exploración y sus reinicios pueden asimismo perjudicar una corrida. La pregunta es si D-MAB mejora *de manera consistente* la calidad de Tabu Search frente a seleccionar los mismos movimientos uniformemente, manteniendo constantes el decodificador, el presupuesto y las soluciones iniciales.

Los trabajos relacionados motivan esta comparación, pero no la resuelven. Akbarzadeh y Maenhout (2024) incorporan varias fases de recursos y predicción de factibilidad en secuenciación quirúrgica; Yin et al. (2026) usan búsqueda tabú con varios operadores entre hospitales. La elección aprendida de operadores también tiene precedentes: Yu et al. (2024) emplean Q-learning en programación y reprogramación de cirugías, mientras Niroumandrad et al. (2024) guían Tabu con clasificadores en otra tarea clínica. DaCosta et al. (2008) proponen D-MAB para selección adaptativa, combinando UCB1 y detección Page–Hinkley, y Dolatkhah et al. (2026) ya aplican D-MAB a operadores genéticos en planificación de quirófanos. Esos aportes impiden reivindicar como novedad general el uso de aprendizaje o de D-MAB en este dominio. La brecha concreta de nuestro estudio es evaluar su integración *dentro de Tabu*, con espera máxima estricta, salas de ambas etapas independientes y una comparación emparejada sobre el caso del curso.

El objetivo de esta primera entrega es especificar la representación, los componentes metaheurístico y de aprendizaje, su interacción y un protocolo reproducible para medir calidad, tiempo y robustez. El repositorio docente (Saicooh, 2026) aporta contexto y datos sintéticos; se trabajó en un repositorio independiente. La presentación menciona cuatro archivos JSON, pero los experimentos disponibles aquí usan doce instancias YAML de la copia local del catálogo. Esta distinción y la función objetivo exacta se declaran para evitar comparaciones impropias con puntajes históricos.

## 2. Propuesta metodológica

### 2.1. Problema, decisiones y decodificación

Sea  $J$  el conjunto de pacientes. Una propuesta  $S = (\pi, \rho^A, \rho^C)$  fija el orden  $\pi$  y las salas preferidas  $\rho^A$  y  $\rho^C$  para anestesia y cirugía. Un planificador asigna personal elegible y ubica cada etapa según los recursos disponibles. La espera y el makespan se definen con el límite estricto:

$$W_j = \max\{0, T_j^C - F_j^A\}, \quad 0 \leq W_j \leq L_j, \quad C_{\max} = \max_{j \in J} F_j^C, \quad (1)$$

Aquí  $j \in J$  es un paciente;  $F_j^A$  y  $F_j^C$ , los fines de anestesia y cirugía con limpieza;  $T_j^C$ , el inicio de cirugía;  $W_j$ , la espera;  $L_j$ , su límite estricto, y  $C_{\max}$ , el fin de la última cirugía. Salas y profesionales deben ser elegibles y no superponerse. La sala de anestesia sigue ocupada hasta el traslado si las salas difieren.

Las claves aleatorias codifican orden y salas. El decodificador pospone pacientes no programables y repara salas incompatibles; así puede modificar movimientos y limitar los calendarios alcanzables. No fuerza equilibrio ni sala común entre etapas.

Minimizamos el criterio fijado antes de la validación,

$$f(S) = C_{\max} + 10^{-6} \sum_o t_o^{\text{ini}} + 0,5 \sum_{j \in J} W_j + 1,4 \max_{j \in J} W_j, \quad (2)$$

En (2),  $f(S)$  es el objetivo;  $o$  recorre las operaciones y  $t_o^{\text{ini}}$  es su inicio de reserva.  $C_{\max}$ ,  $J$  y  $W_j$  se definieron en (1).  $10^{-6}$  desempata; 0,5 y 1,4 ponderan espera total y máxima. No se penaliza el desequilibrio de salas porque podría favorecer el tiempo y la espera. Así,  $f$  difiere del puntaje del taller (Lara Arce, 2026).

### 2.2. Componente metaheurístico: búsqueda tabú

Se inicia con la mejor de treinta soluciones: FIFO, SPT, LPT y veintisiete órdenes aleatorios. Cada ronda genera quince vecinos por intercambio, inserción o cambio de una o ambas salas; se priorizan pacientes con mayor espera ( $p = 0,65$ ). La memoria tabú evita las siete soluciones recientes, salvo mejora global. Las políticas comparten inicio, movimientos y planificador, con 3.030 evaluaciones estrictas, incluidas las treinta iniciales.

### 2.3. Componente de aprendizaje y flujo

El aprendizaje ocurre *online*, sin entrenamiento previo ni variables contextuales. Antes de cada candidato, D-MAB elige un movimiento con UCB1:

$$a^* = \arg \max_a \left( \bar{r}_a + \sqrt{\frac{2 \ln(\sum_b n_b)}{n_a}} \right), \quad (3)$$

En (3),  $a^*$  es el movimiento elegido;  $a$  y  $b$  recorren los cinco movimientos;  $n_a$  y  $n_b$  cuentan sus elecciones, y  $\bar{r}_a$  es la recompensa media de  $a$ . Se prueba cada movimiento antes de aplicar UCB1.

La recompensa se calcula como

$$r_a = \min \left\{ 1, \frac{\max\{0, f(S_{\text{local}}) - f(S_{\text{cand}})\}}{\max\{1, 0,02f(S_{\text{inicial}})\}} \right\}. \quad (4)$$

En (4),  $r_a \in [0, 1]$  es la recompensa;  $S_{\text{local}}$  es el estado al iniciar el lote de quince candidatos,  $S_{\text{cand}}$  el candidato y  $S_{\text{inicial}}$  el inicio.  $f$  es el objetivo de (2). Se premian mejoras normalizadas; un duplicado recibe cero sin gastar evaluación estricta. Page–Hinkley detecta caídas con  $\delta = 0,01$  y umbral  $\lambda = 0,35$ ; reinicia estimaciones, pero conserva la solución y la memoria tabú.

Fuera de línea se fijan instancias, parámetros, métricas y semillas. En línea se selecciona, genera, repara y evalúa el vecino, y se actualizan bandido y Tabu. La ablación UCB1 omite Page–Hinkley; Tabu mixto elige movimientos uniformemente. El bandido aprende la utilidad de la *propuesta reparada*, sin diagnosticar directamente un óptimo local.

## 2.4. Datos, evaluación y alcance de la evidencia

Usamos doce instancias YAML sintéticas, tres de cada tamaño: 15, 20, 25 y 30 cirugías. Se verifican esquema y hashes, y se registran recursos, duraciones y límites de espera. Son datos descriptivos, no entradas del bandido; no hay datos clínicos. Las semillas 0–19 fijaron el piloto; 20–39 validan en *las mismas instancias*: tres políticas por pareja, 720 corridas y 2.181.600 evaluaciones presupuestadas. Se miden objetivo, makespan, esperas, factibilidad, tiempo y convergencia. La mediana fue cercana a 0,9 segundos por corrida; 36 calendarios reejecutados fueron factibles y reprodujeron los valores. FIFO, SPT y LPT también siembran Tabu: superarlas no prueba por sí solo el beneficio del aprendizaje.

Tabla 1: Comparación preliminar frente a Tabu mixto en 240 pares instancia–semilla. Un cambio de hasta 0,25 min se considera similar.

| Política     | Mejora | Similar | Empeora |
|--------------|--------|---------|---------|
| Tabu + UCB1  | 105    | 34      | 101     |
| Tabu + D-MAB | 106    | 39      | 95      |

La tabla 1 no muestra ventaja consistente de D-MAB: el efecto cambia de signo entre instancias y la ablación no favorece al detector. La espera mediana fue cero en todas las políticas, por lo que el catálogo distingue poco el bloqueo. Las semillas nuevas no equivalen a instancias nuevas; igualar evaluaciones tampoco iguala tiempo ni intentos duplicados. La reparación puede cambiar el movimiento elegido. No se infiere superioridad general ni optimalidad; faltan intervalos agrupados por instancia y escenarios más congestionados.

### 3. Conclusión

La programación de cirugías electivas requiere coordinar el orden de los pacientes, las salas y el personal, respetando la espera máxima entre anestesia y cirugía. El problema de investigación es decidir si aprender durante la búsqueda qué movimiento conviene proponer aporta más que una selección fija o uniforme. La arquitectura integra búsqueda tabú, que explora calendarios factibles, con D-MAB, que asigna movimientos según sus recompensas recientes y reinicia sus estimaciones ante una caída detectada.

La validación preliminar ofrece un resultado acotado: D-MAB mejora algunas corridas y empeora otras, sin ventaja consistente en las doce instancias conocidas. Además, la escasa espera observada dificulta medir su posible aporte frente al bloqueo. El valor de esta entrega es una comparación reproducible que separa el efecto de la selección aprendida del reinicio dinámico y explicita sus límites. Las próximas pruebas deberán usar instancias reservadas, mayor congestión, análisis de incertidumbre por instancia y presupuestos tanto de evaluaciones como de tiempo.

## REFERENCIAS

- Akbarzadeh, B., & Maenhout, B. (2024). A two-layer heuristic for patient sequencing in the operating room theatre considering multiple resource phases. *Computers & Operations Research*, 170, 106768. <https://doi.org/10.1016/j.cor.2024.106768>
- DaCosta, L., Fialho, A., Schoenauer, M., & Sebag, M. (2008). Adaptive operator selection with dynamic multi-armed bandits. *Proceedings of the Genetic and Evolutionary Computation Conference*, 913-920. <https://doi.org/10.1145/1389095.1389272>
- Dolatkah, M., Hashemi Doulabi, H., Rei, W., & Gendreau, M. (2026). *A reinforcement-learning-based column generation algorithm for integrated operating room planning and scheduling* [Preprint]. arXiv: 2604.22977. <https://arxiv.org/abs/2604.22977>
- Lara Arce, J. (2026, 7 de septiembre). *Presentación Hospitales: Optativo* [Material de clase, OII464].
- Niroumandrad, N., Lahrichi, N., & Lodi, A. (2024). Learning tabu search algorithms: A scheduling application. *Computers & Operations Research*, 170, 106751. <https://doi.org/10.1016/j.cor.2024.106751>
- Saicooh. (2026). *OII464\_Hospitales* [Repositorio docente de código e instancias]. [https://github.com/Saicooh/OII464\\_Hospitales](https://github.com/Saicooh/OII464_Hospitales)
- Yin, D., Wang, J., Wang, Y., & Punnen, A. (2026). Multi-operator driven iterated tabu search for inter-hospital operating room scheduling. *Journal of the Operational Research Society*, 77(9), 2606-2626. <https://doi.org/10.1080/01605682.2025.2554741>
- Yu, H., Gao, K.-Z., Wu, N., & Suganthan, P. N. (2024). Ensemble meta-heuristics and Q-learning for staff dissatisfaction constrained surgery scheduling and rescheduling. *Engineering Applications of Artificial Intelligence*, 134, 108668. <https://doi.org/10.1016/j.engappai.2024.108668>